

HerAI Fellowship

DEEP LEARNING

Modul Belajar Praktis dan Mudah Dipahami

Dari konsep neuron hingga proyek klasifikasi gambar

Level	Intermediate
Estimasi belajar	18-22 jam
Prasyarat	Python dasar, matematika dasar, dan konsep machine learning
Versi	1.0 - 23 Juli 2026

Disusun untuk Participant Module - Project HerAI

Tentang Modul Ini

Modul ini dirancang untuk membantu peserta memahami deep learning secara bertahap. Setiap konsep dijelaskan dengan bahasa sederhana, analogi, contoh, latihan, dan checkpoint pemahaman.

Fokus modul bukan menghafal rumus. Tujuan utamanya adalah memahami apa yang terjadi ketika sebuah neural network menerima data, membuat prediksi, melakukan kesalahan, lalu memperbaiki dirinya melalui proses training.

Cara belajar yang disarankan

Baca satu bab, kerjakan checkpoint tanpa melihat jawaban, lalu praktikkan latihan. Jangan terburu-buru menuju kode sebelum memahami alur data dan tujuan setiap komponen.

Capaian Pembelajaran

- Menjelaskan perbedaan machine learning dan deep learning.
- Memahami neuron, layer, activation function, loss function, dan optimizer.
- Menjelaskan forward propagation dan backpropagation secara intuitif.
- Menyusun training loop dan membaca gejala training yang bermasalah.
- Mengurangi overfitting dengan regularisasi dan data augmentation.
- Memahami cara kerja dasar CNN, RNN, dan Transformer.
- Mengevaluasi model dengan metrik yang sesuai.
- Membangun mini project klasifikasi gambar dari persiapan data hingga laporan hasil.

Prasyarat

Peserta sebaiknya sudah mengenal variabel, fungsi, list, loop, dan library Python dasar. Pemahaman tentang train-test split, fitur, label, serta supervised learning akan sangat membantu.

Tidak harus ahli matematika

Cukup pahami operasi dasar, grafik, rata-rata, dan intuisi turunan sebagai arah perubahan. Rumus dipakai untuk memperjelas ide, bukan untuk membebani proses belajar.

Peta Materi

Bab	Topik utama	Hasil yang diharapkan
1	Pengantar Deep Learning	Memahami kapan deep learning dibutuhkan.
2	Neuron dan Arsitektur Dasar	Membaca alur input, bobot, bias, aktivasi, dan output.
3	Forward, Loss, dan Backpropagation	Memahami bagaimana model belajar dari kesalahan.
4	Training dan Optimizer	Menjalankan training loop serta mengenali masalah umum.
5	Regularisasi dan Generalisasi	Mengurangi overfitting dan meningkatkan performa pada data baru.
6	Convolutional Neural Network	Memahami pemrosesan citra dengan filter dan feature map.
7	RNN dan Data Berurutan	Memahami data teks, waktu, dan urutan.

Bab	Topik utama	Hasil yang diharapkan
8	Transformer Dasar	Memahami attention, embedding, dan positional information.
9	Evaluasi dan Implementasi	Menilai model secara benar dan menyiapkan penggunaan praktis.
10	Mini Project	Menyelesaikan proyek klasifikasi gambar end-to-end.

BAB 1

Pengantar Deep Learning

Mengenali masalah yang cocok diselesaikan dengan neural network bertingkat.

1.1 Apa Itu Deep Learning?

Deep learning adalah bagian dari machine learning yang menggunakan neural network dengan banyak lapisan. Istilah deep mengacu pada banyaknya tahapan pemrosesan yang dilalui data, bukan berarti model selalu lebih pintar.

Pada machine learning klasik, manusia sering menentukan fitur terlebih dahulu. Contohnya, untuk mengenali gambar kucing, kita mungkin merancang fitur tentang bentuk telinga, panjang kumis, atau warna bulu. Pada deep learning, model belajar sendiri pola yang berguna langsung dari data, selama tersedia data dan proses training yang memadai.

Analogi sederhana

Bayangkan seorang peserta belajar mengenali buah. Pada awalnya ia melihat warna. Setelah berlatih, ia juga memperhatikan tekstur, bentuk, ukuran, dan pola permukaan. Lapisan neural network bekerja serupa: lapisan awal menangkap pola sederhana, sedangkan lapisan lebih dalam menggabungkannya menjadi pola yang lebih kompleks.

1.2 Machine Learning vs Deep Learning

Aspek	Machine Learning Klasik	Deep Learning
Fitur	Sering dirancang manual	Banyak fitur dipelajari otomatis
Kebutuhan data	Dapat bekerja dengan data lebih sedikit	Biasanya membutuhkan data lebih banyak
Komputasi	Relatif ringan	Sering membutuhkan GPU atau akselerator
Interpretasi	Sering lebih mudah dijelaskan	Sering lebih sulit dijelaskan
Kinerja pada data kompleks	Terbatas pada fitur yang dirancang	Sangat kuat untuk gambar, suara, teks, dan multimodal

1.3 Kapan Deep Learning Layak Digunakan?

- Data berupa gambar, suara, teks panjang, video, atau gabungan beberapa jenis data.
- Pola sulit dirancang secara manual, tetapi tersedia banyak contoh data.
- Masalah membutuhkan representasi yang kompleks, misalnya deteksi objek atau pemahaman bahasa.
- Tersedia sumber daya komputasi dan waktu eksperimen yang cukup.

Tidak selalu menjadi pilihan terbaik

Untuk data tabular kecil, model seperti logistic regression, decision tree, random forest, atau gradient boosting dapat lebih cepat, lebih murah, dan lebih mudah dijelaskan.

1.4 Contoh Penerapan

Bidang	Contoh masalah	Output model
Computer Vision	Klasifikasi penyakit dari citra medis	Probabilitas kelas atau lokasi objek
Natural Language Processing	Klasifikasi sentimen atau ringkasan teks	Label, skor, atau teks baru
Speech	Mengubah suara menjadi teks	Transkripsi
Rekomendasi	Memprediksi konten yang relevan	Skor atau peringkat item
Forecasting	Memprediksi permintaan atau beban	Nilai numerik masa depan

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

1. Mengapa deep learning disebut deep?
2. Apa kelemahan menggunakan deep learning pada dataset yang sangat kecil?
3. Sebutkan satu kondisi ketika model klasik lebih masuk akal daripada neural network.

Latihan 1 - Memilih Pendekatan yang Tepat

Tujuan latihan

Melatih kemampuan memilih apakah suatu masalah perlu deep learning.

Tingkat kesulitan: Dasar

Langkah kerja

4. Pilih tiga kasus: prediksi kelulusan dari 500 baris data tabular, klasifikasi 100.000 gambar produk, dan deteksi spam dari 2.000 email.
5. Untuk setiap kasus, tuliskan kandidat model awal yang paling sederhana.
6. Jelaskan kapan deep learning baru layak dicoba.

Hasil yang dikumpulkan: Tabel berisi kasus, pendekatan awal, alasan, dan risiko penggunaan deep learning.

BAB 2

Neuron dan Arsitektur Dasar

Membongkar neural network menjadi komponen kecil yang mudah dipahami.

2.1 Neuron Buatan

Neuron buatan menerima beberapa nilai input. Setiap input dikalikan dengan bobot. Hasilnya dijumlahkan bersama sebuah bias. Nilai tersebut kemudian dilewatkan melalui activation function untuk menghasilkan output.

Bobot menunjukkan seberapa kuat pengaruh sebuah input. Bias memberi fleksibilitas agar neuron tidak selalu bergantung pada titik nol.

Rumus sederhana neuron

$$z = (x_1 * w_1) + (x_2 * w_2) + \dots + b$$

$$y = \text{activation}(z)$$

Analogi panel penilaian

Bayangkan beberapa juri memberi nilai pada sebuah proposal. Setiap juri memiliki bobot berbeda. Bias adalah kecenderungan awal panel. Activation function menentukan apakah skor akhir cukup kuat untuk diteruskan.

2.2 Layer: Input, Hidden, Output

Jenis layer	Peran	Contoh
Input layer	Menerima data awal	784 nilai piksel untuk gambar 28 x 28
Hidden layer	Mengubah representasi data	Menggabungkan garis menjadi bentuk
Output layer	Menghasilkan prediksi	10 probabilitas untuk digit 0-9

Sebuah jaringan disebut fully connected ketika setiap neuron pada satu layer terhubung ke seluruh neuron di layer berikutnya. Arsitektur ini sederhana, tetapi jumlah parameternya dapat membesar dengan cepat.

2.3 Activation Function

Aktivasi	Intuisi	Umum digunakan untuk
ReLU	Nilai negatif menjadi 0; nilai positif diteruskan	Hidden layer pada banyak model
Sigmoid	Mengubah nilai menjadi 0 sampai 1	Output klasifikasi biner
Tanh	Mengubah nilai menjadi -1 sampai 1	Beberapa model berurutan
Softmax	Mengubah sekumpulan skor menjadi probabilitas	Output klasifikasi multikelas

Mengapa aktivasi penting?

Tanpa activation function non-linear, tumpukan banyak layer tetap setara dengan satu transformasi linear. Model tidak akan mampu mempelajari hubungan yang kompleks.

2.4 Parameter dan Hyperparameter

Jenis	Dipelajari model?	Contoh
Parameter	Ya	Weight dan bias
Hyperparameter	Tidak, ditentukan sebelum atau selama eksperimen	Learning rate, batch size, jumlah layer, dropout rate

2.5 Menghitung Jumlah Parameter

Untuk dense layer dengan 8 input dan 4 neuron output, jumlah weight adalah 8×4 . Setiap neuron output juga memiliki satu bias, sehingga total parameter adalah $32 + 4 = 36$.

```
jumlah_parameter = (jumlah_input * jumlah_neuron) + jumlah_neuron
```

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

7. Apa perbedaan weight dan bias?
8. Mengapa ReLU sering digunakan pada hidden layer?
9. Berapa jumlah parameter pada dense layer dengan 10 input dan 3 output?

Latihan 2 - Membaca Arsitektur

Tujuan latihan

Mengenali bentuk tensor dan jumlah parameter pada neural network sederhana.

Tingkat kesulitan: Dasar

Langkah kerja

10. Buat arsitektur: input 20 fitur, hidden layer 16 neuron, hidden layer 8 neuron, output 3 kelas.
11. Hitung parameter pada setiap layer.
12. Tentukan activation function yang masuk akal untuk hidden dan output layer.
13. Jelaskan bentuk output untuk satu sampel.

Hasil yang dikumpulkan: Perhitungan parameter, pilihan activation function, dan penjelasan bentuk output.

BAB 3

Forward, Loss, dan Backpropagation

Memahami bagaimana prediksi dibuat dan bagaimana kesalahan digunakan untuk belajar.

3.1 Forward Propagation

Forward propagation adalah aliran data dari input menuju output. Setiap layer menerima nilai dari layer sebelumnya, melakukan transformasi, lalu meneruskan hasilnya.

Pada tahap ini model belum memperbaiki apa pun. Model hanya menggunakan weight dan bias saat ini untuk menghasilkan prediksi.

Urutan forward pass

Input -> transformasi linear -> activation -> hidden representation -> output -> prediksi.

3.2 Loss Function

Loss function mengukur seberapa jauh prediksi model dari jawaban benar. Nilai loss kecil berarti prediksi lebih dekat dengan target. Training bertujuan menurunkan loss secara bertahap.

Masalah	Loss yang umum	Contoh
Regresi	Mean Squared Error	Prediksi harga rumah
Klasifikasi biner	Binary Cross-Entropy	Spam atau bukan spam
Klasifikasi multikelas	Categorical Cross-Entropy	Kelas digit 0-9

Loss bukan accuracy

Accuracy menghitung proporsi prediksi benar. Loss memperhatikan tingkat keyakinan model dan memberi sinyal yang lebih halus untuk proses belajar.

3.3 Gradient

Gradient menunjukkan arah dan besar perubahan loss terhadap sebuah parameter. Jika gradient positif, menaikkan parameter cenderung menaikkan loss. Jika gradient negatif, menaikkan parameter dapat menurunkan loss.

Optimizer menggunakan gradient untuk mengubah weight dan bias ke arah yang diharapkan menurunkan loss.

```
parameter_baru = parameter_lama - learning_rate * gradient
```

3.4 Backpropagation

Backpropagation adalah proses menghitung kontribusi setiap parameter terhadap kesalahan. Proses dimulai dari output, lalu bergerak mundur melalui jaringan menggunakan chain rule.

Secara praktis, framework seperti TensorFlow dan PyTorch menghitung gradient secara otomatis. Namun, memahami alurnya membantu saat model tidak belajar atau gradient menjadi terlalu kecil atau terlalu besar.

Analogi evaluasi proyek

Tim melihat hasil akhir yang kurang baik, lalu menelusuri penyebabnya dari tahap terakhir ke tahap awal. Setiap tahap mendapat bagian tanggung jawab dan diperbaiki sesuai pengaruhnya.

3.5 Satu Langkah Belajar

14. Ambil satu batch data.
15. Lakukan forward propagation.
16. Hitung loss.
17. Hitung gradient melalui backpropagation.
18. Optimizer memperbarui parameter.
19. Ulangi untuk batch berikutnya.

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

20. Apa fungsi loss function?
21. Mengapa gradient diperlukan oleh optimizer?
22. Apa yang terjadi lebih dahulu: forward propagation atau backpropagation?

Latihan 3 - Simulasi Manual Satu Neuron

Tujuan latihan

Melihat hubungan antara prediksi, loss, dan pembaruan parameter.

Tingkat kesulitan: Dasar

Langkah kerja

23. Gunakan satu input $x = 2$, weight $w = 0.5$, bias $b = 0$, dan target $y = 3$.
24. Hitung prediksi linear $\hat{y} = x \cdot w + b$.
25. Hitung squared error $(\hat{y} - y)^2$.
26. Coba ubah w menjadi 1.0 lalu hitung kembali loss.
27. Jelaskan perubahan mana yang membuat prediksi lebih dekat dengan target.

Hasil yang dikumpulkan: Perhitungan dua percobaan dan kesimpulan singkat.

BAB 4

Training dan Optimizer

Menjalankan proses belajar model secara terukur dan mengenali gejala kegagalan training.

4.1 Epoch, Batch, dan Iteration

Istilah	Arti	Contoh
Epoch	Satu kali seluruh data training digunakan	10.000 data selesai dilalui
Batch	Sekelompok data yang diproses bersama	32 sampel
Iteration	Satu kali pembaruan parameter	Satu batch menghasilkan satu update

Jika terdapat 1.000 sampel dan batch size 100, maka satu epoch memiliki sekitar 10 iteration.

4.2 Learning Rate

Learning rate menentukan seberapa besar langkah pembaruan parameter. Nilai terlalu besar dapat membuat loss berosilasi atau bahkan meningkat. Nilai terlalu kecil membuat training sangat lambat.

Tanda learning rate terlalu besar

Loss tidak stabil, melonjak, menghasilkan NaN, atau accuracy tidak pernah membaik.

Tanda learning rate terlalu kecil

Loss turun sangat lambat dan model membutuhkan banyak epoch untuk mencapai hasil yang layak.

4.3 Optimizer Populer

Optimizer	Karakteristik	Kapan dicoba
SGD	Sederhana dan mudah dipahami	Baseline atau saat ingin kontrol lebih jelas
SGD + Momentum	Mengurangi gerakan zig-zag	Masalah dengan arah gradient yang berubah-ubah
Adam	Adaptif dan sering cepat pada awal training	Pilihan awal yang praktis untuk banyak tugas
AdamW	Adam dengan weight decay yang lebih terpisah	Transformer dan model modern

4.4 Training Loop

Pseudocode training loop

```

for epoch in range(num_epochs):
    for x_batch, y_batch in train_loader:
        predictions = model(x_batch)
        loss = loss_function(predictions, y_batch)

        optimizer.zero_grad()
        loss.backward()
        optimizer.step()

    evaluate_on_validation_data()

```

Langkah `zero_grad` penting pada framework seperti PyTorch karena gradient dapat terakumulasi. Evaluasi validation dilakukan tanpa memperbarui parameter.

4.5 Masalah Umum Saat Training

Gejala	Kemungkinan penyebab	Tindakan awal
Loss tidak turun	Learning rate tidak cocok, label salah, data tidak ternormalisasi	Periksa pipeline data dan coba overfit batch kecil
Loss menjadi NaN	Learning rate terlalu besar, nilai input ekstrem, operasi numerik tidak stabil	Turunkan learning rate dan cek data
Training bagus, validation buruk	Overfitting	Regularisasi, augmentasi, atau lebih banyak data
Accuracy stagnan di tebakan acak	Output/loss tidak cocok, label mapping salah	Periksa activation dan loss
Training sangat lambat	Model terlalu besar, input terlalu besar, pipeline lambat	Profiling dan sederhanakan baseline

4.6 Teknik Debugging Penting

- Coba overfit 10-50 sampel. Jika model tidak bisa menghafal data kecil, ada kemungkinan bug.
- Periksa bentuk tensor pada setiap tahap.
- Lihat distribusi label dan pastikan tidak tertukar.
- Pastikan preprocessing training dan validation konsisten.
- Catat eksperimen: arsitektur, learning rate, batch size, seed, dan hasil.

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

28. Apa perbedaan epoch dan iteration?
29. Mengapa validation data tidak boleh dipakai untuk memperbarui weight?
30. Apa tes sederhana untuk mengecek apakah pipeline dan model dapat belajar?

Latihan 4 - Diagnosis Kurva Training

Tujuan latihan

Membaca pola loss dan accuracy untuk menentukan tindakan berikutnya.

Tingkat kesulitan: Menengah

Langkah kerja

31. Buat tiga skenario: loss training dan validation sama-sama turun; training turun tetapi validation naik; keduanya datar.
32. Untuk setiap skenario, jelaskan diagnosis paling mungkin.
33. Tuliskan dua tindakan yang dapat dicoba.

Hasil yang dikumpulkan: Tabel diagnosis dan tindakan per skenario.

BAB 5

Regularisasi dan Generalisasi

Membuat model tidak hanya menghafal data training, tetapi juga bekerja pada data baru.

5.1 Overfitting dan Underfitting

Kondisi	Ciri	Makna
Underfitting	Training dan validation sama-sama buruk	Model belum menangkap pola
Fit yang baik	Training baik, validation juga baik dan stabil	Model belajar pola yang dapat digeneralisasi
Overfitting	Training sangat baik, validation jauh lebih buruk	Model terlalu menghafal data training

5.2 Dropout

Dropout menonaktifkan sebagian neuron secara acak selama training. Tujuannya agar model tidak terlalu bergantung pada jalur tertentu. Saat inference, seluruh neuron digunakan dengan penyesuaian skala yang ditangani framework.

Intuisi dropout

Seperti melatih tim tanpa selalu mengandalkan satu orang. Setiap anggota harus mampu berkontribusi sehingga tim lebih tahan ketika kondisi berubah.

5.3 Weight Decay

Weight decay mendorong parameter agar tidak tumbuh terlalu besar. Model dengan parameter yang lebih terkendali sering memiliki batas keputusan yang lebih halus dan lebih mudah melakukan generalisasi.

5.4 Normalization

Teknik	Ide dasar	Catatan
Input normalization	Menyetarakan skala data input	Hampir selalu penting
Batch Normalization	Menormalkan aktivasi berdasarkan batch	Umum pada CNN
Layer Normalization	Menormalkan fitur dalam satu sampel	Umum pada Transformer

5.5 Data Augmentation

Data augmentation membuat variasi baru dari data training tanpa mengubah label. Pada gambar, contohnya flip, crop, rotasi kecil, perubahan brightness, atau noise ringan. Transformasi harus tetap masuk akal untuk konteks masalah.

Hati-hati pada transformasi

Membalik gambar angka 6 dapat mengubah makna menjadi 9. Rotasi besar pada citra medis juga bisa tidak realistis. Augmentasi harus mengikuti karakteristik domain.

5.6 Early Stopping

Early stopping menghentikan training ketika performa validation tidak membaik selama beberapa epoch. Simpan checkpoint terbaik, bukan hanya model dari epoch terakhir.

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

- 34. Apa perbedaan overfitting dan underfitting?
- 35. Mengapa data augmentation hanya diterapkan pada training data?
- 36. Apa manfaat menyimpan model dengan validation loss terbaik?

Latihan 5 - Rencana Mengurangi Overfitting

Tujuan latihan

Menyusun intervensi bertahap untuk model yang menghafal data training.

Tingkat kesulitan: Menengah

Langkah kerja

- 37. Gunakan skenario: training accuracy 99%, validation accuracy 72%.
- 38. Susun urutan tiga eksperimen dari yang paling murah.
- 39. Tentukan metrik yang diamati dan kriteria berhasil.
- 40. Jelaskan mengapa mengubah banyak hal sekaligus membuat eksperimen sulit dianalisis.

Hasil yang dikumpulkan: Rencana eksperimen berurutan lengkap dengan hipotesis dan metrik.

BAB 6

Convolutional Neural Network

Memahami bagaimana model melihat pola lokal pada gambar.

6.1 Mengapa Dense Layer Tidak Ideal untuk Gambar Besar?

Gambar memiliki struktur ruang. Piksel yang berdekatan biasanya saling berkaitan. Jika gambar langsung diratakan menjadi satu vektor, hubungan lokal ini tidak digunakan secara efisien.

CNN menggunakan filter kecil yang digeser di seluruh gambar. Filter yang sama digunakan berulang kali sehingga jumlah parameter lebih hemat dan pola dapat dikenali di berbagai posisi.

6.2 Convolution dan Filter

Filter atau kernel adalah matriks kecil, misalnya 3×3 . Filter bergerak di atas gambar, melakukan perkalian elemen, lalu menjumlahkannya untuk menghasilkan feature map. Selama training, nilai filter dipelajari otomatis.

Lapisan awal dan lapisan dalam

Lapisan awal sering belajar tepi dan tekstur. Lapisan lebih dalam menggabungkan fitur menjadi bagian objek, kemudian menjadi representasi objek yang lebih utuh.

6.3 Stride, Padding, dan Pooling

Istilah	Arti	Dampak
Stride	Jarak perpindahan filter	Stride lebih besar mengecilkan feature map
Padding	Menambah batas di sekitar gambar	Membantu mempertahankan ukuran
Pooling	Merangkum area lokal	Mengurangi ukuran dan komputasi

Max pooling mengambil nilai terbesar pada area tertentu. Global average pooling merata-ratakan setiap feature map dan sering digunakan sebelum output layer.

6.4 Arsitektur CNN Sederhana

Alur CNN dasar

```

Input image
-> Conv2D + ReLU
-> MaxPool
-> Conv2D + ReLU
-> MaxPool
-> GlobalAveragePooling
-> Dense output
  
```

6.5 Transfer Learning

Transfer learning menggunakan model yang telah dilatih pada dataset besar sebagai feature extractor. Pendekatan ini sangat berguna ketika dataset sendiri terbatas.

Tahap umum: pilih backbone, ganti classification head, bekukan sebagian layer, latih head, lalu lakukan fine-tuning dengan learning rate kecil.

Baseline yang praktis

Untuk dataset gambar kecil hingga menengah, transfer learning biasanya menjadi baseline yang lebih kuat daripada melatih CNN besar dari nol.

6.6 Contoh Kode Keras

Contoh model klasifikasi gambar tiga kelas

```
import tensorflow as tf

model = tf.keras.Sequential([
    tf.keras.layers.Input(shape=(128, 128, 3)),
    tf.keras.layers.Rescaling(1./255),
    tf.keras.layers.Conv2D(32, 3, activation='relu'),
    tf.keras.layers.MaxPooling2D(),
    tf.keras.layers.Conv2D(64, 3, activation='relu'),
    tf.keras.layers.GlobalAveragePooling2D(),
    tf.keras.layers.Dense(3, activation='softmax')
])

model.compile(
    optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy']
)
```

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

41. Mengapa CNN menggunakan filter yang sama pada banyak posisi?
42. Apa fungsi pooling?
43. Kapan transfer learning lebih masuk akal daripada training dari nol?

Latihan 6 - Mendesain CNN Baseline

Tujuan latihan

Menyusun CNN kecil yang sesuai dengan ukuran data dan jumlah kelas.

Tingkat kesulitan: Menengah

Langkah kerja

44. Gunakan input gambar 128 x 128 RGB dan 5 kelas.
45. Rancang dua blok convolution dan satu output layer.
46. Tuliskan bentuk output setelah setiap tahap secara kasar.
47. Tambahkan satu strategi regularisasi.

Hasil yang dikumpulkan: Diagram arsitektur, alasan desain, dan estimasi perubahan bentuk tensor.

BAB 7

RNN dan Data Berurutan

Memahami data yang urutannya membawa makna, seperti teks dan deret waktu.

7.1 Mengapa Urutan Penting?

Pada data berurutan, posisi dan konteks memengaruhi makna. Kalimat “anjing menggigit manusia” berbeda dari “manusia menggigit anjing”, walaupun kata yang digunakan sama.

RNN memproses elemen satu per satu sambil membawa hidden state sebagai ringkasan konteks sebelumnya.

```
hidden_t = f(input_t, hidden_t-1)
```

7.2 Kelemahan RNN Sederhana

RNN sederhana sulit mempertahankan informasi yang sangat jauh karena vanishing gradient atau exploding gradient. LSTM dan GRU menambahkan mekanisme gerbang untuk mengatur informasi yang disimpan, dilupakan, dan diteruskan.

7.3 Bentuk Masalah Sequence

Pola	Contoh
One-to-one	Klasifikasi gambar biasa
Many-to-one	Klasifikasi sentimen dari satu kalimat
One-to-many	Membuat rangkaian output dari satu input
Many-to-many	Terjemahan atau pelabelan setiap token

7.4 RNN, LSTM, atau Transformer?

RNN dan LSTM masih berguna untuk model kecil, data streaming, dan kebutuhan latensi tertentu. Namun, Transformer lebih dominan pada banyak tugas bahasa karena dapat memproses token secara paralel dan menangkap hubungan jarak jauh dengan attention.

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

48. Mengapa urutan kata memengaruhi makna?
49. Apa fungsi hidden state?
50. Masalah apa yang coba diatasi LSTM dan GRU?

Latihan 7 - Memetakan Masalah Sequence

Tujuan latihan

Mengenali input-output pada masalah berurutan.

Tingkat kesulitan: Dasar

Langkah kerja

51. Pilih tiga kasus: sentiment analysis, prediksi suhu harian, dan named entity recognition.
52. Tentukan bentuk input dan output.
53. Tentukan apakah masalahnya many-to-one atau many-to-many.
54. Jelaskan satu risiko preprocessing yang dapat merusak urutan.

Hasil yang dikumpulkan: Tabel kasus, bentuk sequence, tipe mapping, dan risiko preprocessing.

BAB 8

Transformer Dasar

Memahami attention, embedding, dan informasi posisi sebagai fondasi model modern.

8.1 Keterbatasan Pemrosesan Berurutan

RNN memproses token secara bertahap. Hal ini menyulitkan paralelisasi dan membuat hubungan jarak jauh lebih sulit dipelajari. Transformer menggunakan attention agar setiap token dapat mempertimbangkan token lain secara langsung.

8.2 Embedding

Embedding mengubah token menjadi vektor angka. Token dengan konteks atau fungsi yang mirip dapat memiliki representasi yang berdekatan. Embedding dipelajari selama training atau berasal dari model prelatih.

8.3 Self-Attention

Self-attention menghitung seberapa relevan token lain terhadap token yang sedang diproses. Setiap token menghasilkan query, key, dan value.

Query menggambarkan informasi yang dicari. Key menggambarkan karakteristik token. Value membawa informasi yang akan digabungkan. Kecocokan query dan key menentukan bobot attention terhadap value.

Analogi rapat tim

Seseorang mengajukan pertanyaan tertentu. Ia memberi perhatian lebih besar kepada anggota yang pengetahuannya paling relevan. Jawaban akhir merupakan gabungan informasi dengan bobot yang berbeda.

8.4 Positional Information

Self-attention sendiri tidak mengetahui urutan token. Karena itu model menambahkan positional encoding atau positional embedding agar posisi pertama, kedua, dan seterusnya dapat dibedakan.

8.5 Multi-Head Attention

Multi-head attention menjalankan beberapa pola attention secara paralel. Satu head mungkin fokus pada hubungan subjek-predikat, head lain pada referensi kata, dan head lain pada konteks lokal. Hasilnya digabungkan.

8.6 Encoder dan Decoder

Komponen	Fungsi umum	Contoh penggunaan
Encoder	Membangun representasi input	Klasifikasi dan pemahaman teks
Decoder	Menghasilkan token secara bertahap	Text generation
Encoder-decoder	Membaca input lalu menghasilkan output	Terjemahan dan summarization

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

- 55. Apa tujuan embedding?
- 56. Mengapa positional information dibutuhkan?
- 57. Apa peran query, key, dan value dalam attention?

Latihan 8 - Menjelaskan Attention Tanpa Rumus**Tujuan latihan**

Mengkomunikasikan ide self-attention dengan bahasa non-teknis.

Tingkat kesulitan: Menengah

Langkah kerja

- 58. Pilih satu kalimat yang memiliki kata rujukan, misalnya “Rina memberi buku kepada Sari karena ia lulus.”
- 59. Jelaskan token mana yang perlu saling memperhatikan untuk memahami kata “ia”.
- 60. Tuliskan penjelasan self-attention dalam maksimal 150 kata.

Hasil yang dikumpulkan: Penjelasan maksimal 150 kata yang dapat dipahami pemula.

BAB 9

Evaluasi dan Implementasi

Menilai model secara benar, menganalisis kesalahan, dan menyiapkan penggunaan nyata.

9.1 Pembagian Data

Bagian	Fungsi	Catatan
Training	Memperbarui parameter	Boleh menerima augmentation
Validation	Memilih model dan hyperparameter	Tidak dipakai untuk update weight
Test	Estimasi akhir pada data belum terlihat	Gunakan setelah keputusan final

Hindari data leakage

Informasi dari validation atau test tidak boleh bocor ke proses training. Contohnya, normalisasi harus dihitung dari training data lalu diterapkan ke validation dan test.

9.2 Metrik Klasifikasi

Metrik	Makna sederhana	Penting ketika
Accuracy	Proporsi prediksi benar	Kelas relatif seimbang
Precision	Dari prediksi positif, berapa yang benar	False positive mahal
Recall	Dari semua kasus positif, berapa yang ditemukan	False negative mahal
F1-score	Keseimbangan precision dan recall	Kelas tidak seimbang
Confusion matrix	Rincian jenis kesalahan per kelas	Analisis error

9.3 Analisis Kesalahan

- Lihat contoh yang salah, bukan hanya angka agregat.
- Kelompokkan error: kualitas data, label ambigu, kelas mirip, kondisi ekstrem, atau bias domain.
- Periksa performa per kelas dan per segmen pengguna.
- Pastikan sampel salah tidak berasal dari data duplikat atau preprocessing yang rusak.

9.4 Reproducibility

Catat versi data, kode, library, seed, hyperparameter, dan checkpoint. Hasil deep learning dapat berubah karena inisialisasi acak, urutan batch, dan operasi GPU. Reproducibility memudahkan perbandingan eksperimen.

9.5 Inference dan Deployment

Pertimbangan	Pertanyaan
Latency	Seberapa cepat prediksi harus tersedia?

Pertimbangan	Pertanyaan
Ukuran model	Apakah model berjalan di server, browser, atau perangkat mobile?
Throughput	Berapa banyak request yang harus diproses?
Monitoring	Bagaimana mendeteksi penurunan kualitas atau data drift?
Privasi	Apakah data sensitif boleh dikirim ke server?

Model terbaik belum tentu model terbesar

Dalam produk nyata, model yang sedikit kurang akurat tetapi jauh lebih cepat, murah, dan stabil bisa menjadi pilihan yang lebih baik.

Checkpoint Pemahaman

Jawab pertanyaan berikut tanpa melihat materi. Jika masih ragu, ulangi bagian yang terkait.

61. Apa perbedaan validation set dan test set?
62. Kapan recall lebih penting daripada precision?
63. Mengapa analisis contoh yang salah penting setelah melihat metrik?

Latihan 9 - Menentukan Metrik

Tujuan latihan

Memilih metrik berdasarkan dampak kesalahan.

Tingkat kesulitan: Menengah

Langkah kerja

64. Bandingkan dua kasus: deteksi penyakit berisiko tinggi dan penyaringan komentar spam.
65. Jelaskan dampak false positive dan false negative pada masing-masing kasus.
66. Pilih metrik utama dan metrik pendamping.
67. Jelaskan mengapa accuracy saja mungkin menyesatkan.

Hasil yang dikumpulkan: Analisis dampak kesalahan dan rekomendasi metrik.

BAB 10

Mini Project: Klasifikasi Gambar

Menerapkan seluruh alur kerja deep learning dari definisi masalah sampai laporan evaluasi.

10.1 Tujuan Proyek

Membangun model klasifikasi gambar minimal tiga kelas. Dataset dapat berupa jenis sampah, jenis makanan, kondisi daun, kategori produk, atau objek lain yang relevan. Fokus penilaian bukan hanya accuracy, tetapi kualitas proses dan kemampuan menjelaskan keputusan.

10.2 Batasan Proyek

- Minimal 300 gambar secara keseluruhan dan minimal 3 kelas.
- Pisahkan training, validation, dan test secara jelas.
- Buat baseline sederhana sebelum mencoba model kompleks.
- Gunakan minimal satu teknik regularisasi atau augmentation.
- Laporkan confusion matrix dan minimal tiga contoh prediksi salah.
- Simpan model terbaik berdasarkan validation metric.

10.3 Tahapan Pengerjaan

Tahap	Aktivitas utama
Definisi masalah	Tentukan pengguna, tujuan prediksi, kelas, dan dampak kesalahan.
Audit data	Periksa jumlah data, duplikat, kualitas gambar, label, dan ketidakseimbangan kelas.
Split data	Buat training, validation, dan test tanpa kebocoran.
Baseline	Bangun CNN kecil atau transfer learning sederhana.
Eksperimen	Ubah satu faktor setiap kali dan catat hasil.
Evaluasi	Gunakan metrik, confusion matrix, dan analisis error.
Kesimpulan	Jelaskan keterbatasan dan langkah pengembangan.

10.4 Template Laporan

68. Judul dan ringkasan proyek.
69. Latar belakang dan tujuan.
70. Deskripsi dataset dan distribusi kelas.
71. Preprocessing dan augmentation.
72. Arsitektur atau model pralatih yang digunakan.
73. Konfigurasi training dan hyperparameter.
74. Hasil eksperimen dalam tabel.
75. Confusion matrix dan analisis kesalahan.
76. Risiko, keterbatasan, dan rencana peningkatan.

10.5 Tabel Log Eksperimen

ID	Perubahan	Hipotesis	Val metric	Catatan
E01	Baseline CNN	Mendapatkan titik awal	...	...
E02	Tambah augmentation	Mengurangi overfitting	...	...
E03	Transfer learning	Meningkatkan feature quality	...	...

10.6 Rubrik Penilaian

Aspek	Bobot	Kriteria
Definisi masalah	10%	Tujuan, pengguna, kelas, dan dampak kesalahan jelas
Kualitas data	15%	Audit, split, dan preprocessing benar
Metodologi	20%	Baseline dan eksperimen terstruktur
Evaluasi	25%	Metrik sesuai, confusion matrix, dan error analysis
Pemahaman	20%	Mampu menjelaskan alasan desain dan hasil
Dokumentasi	10%	Laporan rapi dan dapat direproduksi

Kriteria kelulusan

Peserta dinyatakan memenuhi kompetensi apabila memperoleh minimal 70/100 dan tidak melakukan data leakage yang mendasar.

BAB 11

Kuis Akhir

Uji pemahaman konsep sebelum menutup modul.

1. Istilah deep pada deep learning terutama mengacu pada ...

- A. ukuran dataset
- B. jumlah lapisan pemrosesan
- C. panjang kode
- D. jenis komputer

2. Komponen yang dipelajari langsung selama training adalah ...

- A. batch size
- B. learning rate
- C. weight dan bias
- D. jumlah epoch

3. Activation function dibutuhkan terutama untuk ...

- A. menambah data
- B. memberi non-linearitas
- C. membagi dataset
- D. menyimpan checkpoint

4. Fungsi utama loss adalah ...

- A. mengukur kesalahan prediksi
- B. memperbesar input
- C. memilih batch
- D. menghapus noise

5. Backpropagation digunakan untuk ...

- A. membagi data
- B. menghitung gradient
- C. melakukan augmentasi
- D. menambah kelas

6. Learning rate terlalu besar sering menyebabkan ...

- A. loss tidak stabil
- B. parameter tidak berubah sama sekali
- C. dataset bertambah
- D. output selalu satu kelas karena softmax

7. Training accuracy sangat tinggi tetapi validation accuracy rendah adalah tanda ...

- A. underfitting
- B. overfitting
- C. data augmentation
- D. normalisasi

8. Dropout bekerja dengan cara ...

- A. menghapus label
- B. menonaktifkan neuron secara acak saat training
- C. memperbesar gambar

- D. mengganti optimizer

9. CNN efektif untuk gambar karena ...

- A. mengabaikan posisi piksel
- B. memakai filter lokal dan weight sharing
- C. selalu memiliki parameter paling banyak
- D. tidak memerlukan data

10. Pooling biasanya digunakan untuk ...

- A. memperbesar resolusi
- B. mengurangi ukuran feature map
- C. menambah kelas
- D. menghitung loss

11. Transfer learning berarti ...

- A. memindahkan file dataset
- B. memakai pengetahuan model pralatih
- C. mengganti bahasa pemrograman
- D. menghapus semua weight

12. Hidden state pada RNN berfungsi sebagai ...

- A. ringkasan konteks sebelumnya
- B. label tambahan
- C. loss function
- D. jenis optimizer

13. Self-attention membantu setiap token ...

- A. menghapus token lain
- B. mempertimbangkan token lain secara langsung
- C. selalu fokus pada token terdekat
- D. menjadi gambar

14. Positional encoding dibutuhkan karena ...

- A. attention tidak otomatis mengetahui urutan
- B. embedding terlalu kecil
- C. optimizer tidak mengenal token
- D. loss tidak memiliki gradient

15. Test set sebaiknya digunakan ...

- A. untuk update weight
- B. berulang kali memilih hyperparameter
- C. untuk evaluasi akhir
- D. sebagai augmentation

16. Recall penting ketika ...

- A. false negative mahal
- B. false positive satu-satunya masalah
- C. semua kelas seimbang pasti
- D. tidak ada label

17. Data leakage terjadi ketika ...

- A. training lambat
- B. informasi test masuk ke proses training

- C. batch size kecil
- D. model disimpan

18. Tes overfit batch kecil berguna untuk ...

- A. mengecek apakah model dan pipeline bisa belajar
- B. mengukur performa final
- C. membuat dataset lebih besar
- D. menghapus gradient

19. Model terbaik untuk produk nyata selalu ...

- A. model terbesar
- B. model paling baru
- C. model dengan kompromi kualitas, biaya, dan latency yang tepat
- D. model dengan epoch terbanyak

20. Eksperimen yang baik sebaiknya ...

- A. mengubah semua hal sekaligus
- B. tidak mencatat konfigurasi
- C. mengubah satu faktor utama setiap kali
- D. hanya melihat training accuracy

Kunci Jawaban

1-B, 2-C, 3-B, 4-A, 5-B, 6-A, 7-B, 8-B, 9-B, 10-B, 11-B, 12-A, 13-B, 14-A, 15-C, 16-A, 17-B, 18-A, 19-C, 20-C

Interpretasi skor

17-20: sangat baik; 14-16: baik; 10-13: perlu mengulang beberapa bab; di bawah 10: ulangi materi inti dan kerjakan latihan sebelum mencoba kembali.

BAB 12

Diskusi dan Refleksi

Menghubungkan konsep teknis dengan keputusan nyata.

Pertanyaan Diskusi

77. Apakah model yang lebih akurat selalu lebih baik untuk digunakan? Jelaskan dengan contoh biaya atau risiko.
78. Bagaimana menentukan apakah masalah kekurangan data atau kekurangan kapasitas model?
79. Apa risiko etis ketika dataset gambar tidak mewakili seluruh kelompok pengguna?
80. Dalam kondisi apa transfer learning dapat membawa bias dari dataset asal?
81. Bagaimana cara menjelaskan keputusan model kepada pengguna non-teknis tanpa memberi klaim berlebihan?

Refleksi Individu

- Konsep mana yang paling mudah dipahami?
- Konsep mana yang masih membingungkan?
- Kesalahan apa yang paling mungkin terjadi ketika Anda membangun model pertama?
- Apa satu eksperimen kecil yang akan Anda lakukan setelah menyelesaikan modul?

BAB 13

Glosarium

Ringkasan istilah penting dalam deep learning.

Istilah	Penjelasan
Activation function	Fungsi non-linear yang menentukan output neuron.
Backpropagation	Proses menghitung gradient dari output kembali ke parameter sebelumnya.
Batch	Sekelompok sampel yang diproses bersama.
Bias	Parameter tambahan yang menggeser hasil transformasi.
Checkpoint	Salinan parameter model yang disimpan pada titik tertentu.
Convolution	Operasi filter lokal pada data seperti gambar.
Data leakage	Masuknya informasi validation atau test ke proses training.
Dropout	Regularisasi dengan menonaktifkan sebagian unit secara acak saat training.
Embedding	Representasi vektor dari token atau objek diskret.
Epoch	Satu kali seluruh training data dilalui.
Feature map	Hasil penerapan filter convolution.
Fine-tuning	Melanjutkan training model pralatih pada data tugas tertentu.
Gradient	Arah dan besar perubahan loss terhadap parameter.
Hyperparameter	Konfigurasi yang ditentukan di luar proses belajar parameter.
Inference	Proses menggunakan model terlatih untuk menghasilkan prediksi.
Learning rate	Besarnya langkah pembaruan parameter.
Loss	Ukuran kesalahan prediksi.
Optimizer	Algoritma pembaruan parameter berdasarkan gradient.
Overfitting	Model terlalu menyesuaikan diri dengan training data.
Parameter	Nilai yang dipelajari model, terutama weight dan bias.
Pooling	Operasi peringkasan area pada feature map.
Regularization	Teknik untuk membantu generalisasi dan mengurangi overfitting.
Self-attention	Mekanisme yang menggabungkan informasi antar token berdasarkan relevansi.
Tensor	Struktur data numerik multidimensi.
Underfitting	Model belum mampu menangkap pola penting.
Validation set	Data untuk mengevaluasi pilihan model selama pengembangan.

Istilah	Penjelasan
Weight	Parameter yang mengatur kekuatan pengaruh input.

BAB 14

Ringkasan Cepat

Checklist praktis sebelum, selama, dan setelah training.

Sebelum Training

- Definisikan tujuan dan dampak kesalahan.
- Audit distribusi data dan label.
- Pisahkan training, validation, dan test.
- Buat baseline sederhana.
- Pastikan preprocessing dapat direproduksi.

Selama Training

- Pantau training loss dan validation loss.
- Simpan checkpoint terbaik.
- Catat hyperparameter dan seed.
- Ubah satu faktor utama per eksperimen.
- Gunakan overfit batch kecil saat debugging.

Setelah Training

- Evaluasi pada test set hanya setelah keputusan final.
- Lihat confusion matrix dan contoh error.
- Periksa performa per kelas dan per segmen.
- Bandingkan kualitas dengan latency dan biaya.
- Dokumentasikan keterbatasan model.

Alur inti deep learning

Data -> preprocessing -> model -> prediksi -> loss -> backpropagation -> optimizer -> evaluasi -> perbaikan.

BAB 15

Referensi Belajar

Sumber lanjutan untuk memperdalam konsep dan praktik.

Sumber	Keterangan
Deep Learning	Ian Goodfellow, Yoshua Bengio, dan Aaron Courville.
Dive into Deep Learning	Aston Zhang, Zachary C. Lipton, Mu Li, dan Alexander J. Smola.
Neural Networks and Deep Learning	Michael Nielsen.
TensorFlow Guides	Dokumentasi resmi TensorFlow untuk model, data pipeline, dan training.
PyTorch Tutorials	Dokumentasi resmi PyTorch untuk autograd, model, dan training loop.
CS231n	Materi Stanford tentang convolutional neural networks untuk visual recognition.
The Illustrated Transformer	Penjelasan visual tentang Transformer dan attention.

Penutup

Deep learning menjadi lebih mudah dipahami ketika dipandang sebagai proses iteratif: model membuat prediksi, mengukur kesalahan, menghitung arah perbaikan, lalu memperbarui parameter.

Kemampuan terpenting bukan menghafal banyak arsitektur, tetapi membangun baseline, membaca gejala training, menganalisis kesalahan, dan membuat keputusan eksperimen yang terukur.

Langkah berikutnya

Setelah menyelesaikan modul ini, peserta siap mempelajari Reinforcement Learning, Large Language Model, atau spesialisasi Computer Vision dengan fondasi yang lebih kuat.

HerAI Fellowship - Participant Module

Course ID: deep-learning | Status: ready | Version: 1.0.0